

Classification Models

جدول المقارنة الرئيسي

الخاصية	Logistic Regression	Random Forest	XGBoost	LightGBM	CatBoost	SVM	Decision Tree
التعقيد الحسابي	$O(nd)$	$O(n \log n \times \text{trees})$	$O(n \log n \times \text{rounds})$	$O(n \log n \times \text{rounds})$	$O(n \log n \times \text{rounds})$	$O(n^2d)$	$O(n \log n)$
قابلية التفسير	عالية جداً	متوسطة	متوسطة	متوسطة	متوسطة	منخفضة	عالية جداً
الأداء مع البيانات الكبيرة	ممتاز	جيد جداً	ممتاز	ممتاز جداً	ممتاز	ضعيف	جيد
مقاومة Overfitting	جيدة	ممتازة	جيدة جداً	جيدة جداً	ممتازة	جيدة	ضعيفة جداً
التعامل مع البيانات المفقودة	يحتاج معالجة	جيد	جيد	جيد	ممتاز	يحتاج معالجة	ممتاز
حساسية للمعايرة	متوسطة	منخفضة	متوسطة	منخفضة	منخفضة جداً	عالية جداً	منخفضة
التعامل مع الفئات غير المتوازنة	ضعيف	جيد	جيد جداً	جيد جداً	جيد جداً	متوسط	ضعيف
مناسب للبيانات عالية الأبعاد	جيد	ممتاز	ممتاز	ممتاز	ممتاز	ممتاز	ضعيف
سرعة التدريب	سريع جداً	متوسط	سريع	سريع جداً	متوسط	بطيء	سريع جداً

التفاصيل الفنية

1. Logistic Regression

- للتنبؤ بالاحتمالات sigmoid function المبدأ: يستخدم
- الافتراضات: العلاقة الخطية بين المتغيرات
- المخرجات: احتمالات + قرار ثنائي
- المعاملات المهمة:
 - `C`: قوة التنظيم (أصغر = تنظيم أكبر)
 - `solver`: طريقة الحل ('liblinear', 'lbfgs')

2. Random Forest

- المبدأ: مجموعة من أشجار القرار + تصويت جماعي
- ويتعامل مع البيانات المعقدة Overfitting القوة: يقلل
- المعاملات المهمة:
 - `n_estimators`: عدد الأشجار (1000-100)
 - `max_depth`: عمق الشجرة
 - `min_samples_split`: أقل عينات للتقسيم

2. Random Forest

- المبدأ: مجموعة من أشجار القرار + تصويت جماعي
- ويتعامل مع البيانات المعقدة Overfitting القوة: يقلل
- المعاملات المهمة:
 - `n_estimators`: عدد الأشجار (1000-100)
 - `max_depth`: عمق الشجرة
 - `min_samples_split`: أقل عينات للتقسيم

3. 🚀 XGBoost (Extreme Gradient Boosting)

- **المبدأ:** Gradient Boosting متقدمة تقنيات + مُحسن
- **overfitting القوة:** أداء ممتاز، سرعة عالية، مقاوم للـ
- **المعاملات المهمة:**
 - `n_estimators`: عدد الـ boosting rounds
 - `learning_rate`: معدل التعلم (0.3-0.01)
 - `max_depth`: عمق الأشجار (10-3)
 - `subsample`: round نسبة العينات لكل

4. ⚡ LightGBM

- **المبدأ:** Gradient Boosting والذاكرة محسن للسرعة
- يستهلك ذاكرة أقل، XGBoost **القوة:** أسرع من
- **المعاملات المهمة:**
 - `num_leaves`: عدد الأوراق (100-31)
 - `learning_rate`: معدل التعلم
 - `feature_fraction`: نسبة المتغيرات المستخدمة
 - `bagging_fraction`: نسبة العينات

5. 🎯 CatBoost

- **المبدأ:** Gradient Boosting الفئوية مُحسن للمتغيرات
- تلقائياً categorical features **القوة:** يتعامل مع الـ
- **المعاملات المهمة:**
 - `iterations`: عدد الـ boosting rounds
 - `learning_rate`: معدل التعلم
 - `depth`: عمق الأشجار

- المتغيرات الفئوية: `cat_features`

6. ✂ Support Vector Machine (SVM)

- **المبدأ:** يجد الحدود المثلى بين الفئات
- **القوة:** ممتاز مع البيانات عالية الأبعاد والعلاقات المعقدة
- **المعاملات المهمة:**
 - قوة التنظيم: `C`
 - `kernel` نوع الـ kernel ('linear', 'rbf', 'poly')
 - تأثير كل نقطة تدريب: `gamma`

7. 🌳 Decision Tree

- **المبدأ:** (if-else) شجرة من القواعد البسيطة
- **القوة:** سهل الفهم والتفسير
- **بسهولة Overfitting:** نقاط الضعف
- **المعاملات المهمة:**
 - عمق الشجرة: `max_depth`
 - أقل عينات في الورقة: `min_samples_leaf`
 - معيار التقسيم: ('gini', 'entropy') `criterion`

8. 🎯 K-Nearest Neighbors (KNN)

- جيران K **المبدأ:** يصنف بناءً على أقرب
- **القوة:** بسيط وفعال مع البيانات المحلية
- **المعاملات المهمة:**
 - عدد الجيران (5-15 عادة): `n_neighbors`
 - طريقة الوزن: ('uniform', 'distance') `weights`
 - مقياس المسافة: ('euclidean', 'manhattan') `metric`

9. 📊 Naive Bayes

- **المبدأ:** يفترض استقلالية المتغيرات + قانون بايز
- **القوة:** سريع جداً، جيد مع النصوص
- **الأنواع:**
 - GaussianNB: للبيانات المستمرة
 - MultinomialNB: للبيانات المنفصلة
 - BernoulliNB: للبيانات الثنائية

10. 🧠 Neural Networks

- **المبدأ:** شبكة من العقد المترابطة
- **القوة:** يتعلم العلاقات المعقدة جداً
- **المعاملات المهمة:**
 - hidden_layer_sizes: حجم الطبقات المخفية
 - activation: دالة التنشيط ('relu', 'tanh')
 - learning_rate: معدل التعلم

الفئة الجديدة: Gradient Boosting Models 🚀

🏆 أقوى النماذج للمسابقات والإنتاج

1. **XGBoost:** الأشهر والأكثر استقراراً
2. **LightGBM:** الأسرع والأقل استهلاكاً للذاكرة
3. **CatBoost:** الأفضل مع البيانات الفئوية

💪 Gradient Boosting: مميزات

- دقة عالية جداً (يفوز في أغلب المسابقات)
- يتعامل مع أي نوع بيانات

- (نسبياً) overfitting مقاوم للـ
- feature importance يعطي

متى نستخدم كل نموذج؟

🎯 حسب طبيعة المشكلة:

للمشاكل البسيطة والسريعة:

- Logistic Regression, Naive Bayes

للدقة العالية:

- Random Forest, SVM, Neural Networks

للتفسير والفهم:

- Decision Tree, Logistic Regression

للبينات الكبيرة:

- Logistic Regression, Naive Bayes, Random Forest

📊 حسب نوع البيانات:

نوع البيانات	الأفضل	البديل
نصوص	Naive Bayes	Logistic Regression
صور	Neural Networks	SVM
بيانات جدولية	Random Forest	Logistic Regression
بيانات زمنية	Neural Networks	Random Forest
بيانات فئوية	Decision Tree	Naive Bayes

⚡ حسب الأولوية:

السرعة أهم شيء

1. Naive Bayes
2. Logistic Regression
3. KNN

:الدقة أهم شيء

1. Random Forest
2. Neural Networks
3. SVM

:التفسير أهم شيء

1. Decision Tree
2. Logistic Regression
3. Naive Bayes

نصائح للاختيار العملي

🚀:استراتيجية البداية السريعة

1. **Logistic Regression** (baseline سريع) ابدأ بـ
2. **Random Forest** (أداء جيد عادة) جرب
3. **Neural Networks** أو **SVM** إذا النتائج مش كافية، جرب

💡:قواعد ذهبية

- Random Forest مشكلة جديدة؟ ابدأ بـ
- Decision Tree أو KNN بيانات أقل من 1000؟
- Decision Tree أو Logistic Regression محتاج تفسير؟
- Naive Bayes بيانات نصية؟
- Neural Networks مشكلة معقدة جداً؟

⚠️ تحذيرات مهمة:

- **KNN:** بطيء جداً مع البيانات الكبيرة
- **Decision Tree:** (overfitting) يحفظ البيانات بسهولة
- **SVM:** يحتاج معايرة دقيقة جداً
- **Neural Networks:** يحتاج بيانات كثير ووقت تدريب طويل