

Regression Models) مقارنة نماذج الانحدار

جدول المقارنة الرئيسي

الخاصية	Linear Regression	Ridge	Lasso	Elastic Net	Random Forest	XGBoost
التعقيد الحسابي	$O(nd^2)$	$O(nd^2)$	$O(nd^2)$	$O(nd^2)$	$O(n \log n \times \text{trees})$	$O(n \log n \times \text{rounds})$
قابلية التفسير	عالية جداً	عالية	عالية	عالية	متوسطة	متوسطة
الأداء مع البيانات الكبيرة	ممتاز	ممتاز	ممتاز	ممتاز	جيد جداً	ممتاز
مقاومة Overfitting	ضعيفة	جيدة جداً	جيدة جداً	ممتازة	ممتازة	جيدة جداً
التعامل مع البيانات المفقودة	يحتاج معالجة	يحتاج معالجة	يحتاج معالجة	يحتاج معالجة	جيد	جيد
حساسية للمعايرة	منخفضة	متوسطة	متوسطة	متوسطة	منخفضة	متوسطة
Feature Selection	لا	لا	نعم (تلقائي)	نعم (متوازن)	نعم (importance)	نعم (importance)
التعامل مع Multicollinearity	ضعيف جداً	ممتاز	جيد	ممتاز	جيد	جيد
مناسب للبيانات عالية الأبعاد	ضعيف	جيد	ممتاز	ممتاز	ممتاز	ممتاز
سرعة التدريب	سريع جداً	سريع جداً	سريع جداً	سريع جداً	متوسط	سريع

التفاصيل الفنية

1. Linear Regression

- **المبدأ:** يفترض علاقة خطية بين المتغيرات والهدف
- **المعادلة:** $y = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \dots + \beta_n x_n$
- **الافتراضات:** خطية، عدم ارتباط الأخطاء، توزيع طبيعي للأخطاء
- **المخرجات:** معاملات واضحة المعنى

2. Ridge Regression (L2 Regularization)

- **المبدأ:** Linear regression + معاملة L2 للتنظيم
- **المعادلة:** $\text{Loss} + \alpha \times \sum(\beta_i^2)$
- **multicollinearity القوة:** يقلل المعاملات الكبيرة، يحل مشكلة
- **المعاملات المهمة:**
 - α : قوة التنظيم (100-0.1)

3. Lasso Regression (L1 Regularization)

- **المبدأ:** Linear regression + معاملة L1 للتنظيم
- **المعادلة:** $\text{Loss} + \alpha \times \sum|\beta_i|$
- **القوة:** (feature selection) يصفّر المعاملات غير المهمة
- **المعاملات المهمة:**
 - α : قوة التنظيم (10-0.01)

4. Elastic Net

- **المبدأ:** Ridge و Lasso يجمع بين
- **المعادلة:** $\text{Loss} + \alpha_1 \times \sum|\beta_i| + \alpha_2 \times \sum(\beta_i^2)$
- **feature selection القوة:** يوازن بين

- **المعاملات المهمة:**
 - `alpha`: قوة التنظيم الإجمالي
 - `l1_ratio`: نسبة L1 إلى L2 (0-1)

5. 🌳 Random Forest Regressor

- **المبدأ:** مجموعة من أشجار الانحدار + متوسط النتائج
- **overfitting القوة:** يتعامل مع العلاقات غير الخطية، مقاوم للـ
- **المعاملات المهمة:**
 - `n_estimators`: عدد الأشجار (100-1000)
 - `max_features`: عدد المتغيرات لكل انقسام

6. 🚀 XGBoost Regressor

- **المبدأ:** Gradient boosting محسن بتقنيات متقدمة
- **القوة:** دقة عالية جداً، يتعامل مع أي نوع علاقة
- **المعاملات المهمة:**
 - `n_estimators`: عدد الـ rounds (100-1000)
 - `learning_rate`: معدل التعلم (0.3-0.01)
 - `max_depth`: عمق الأشجار (10-3)

7. ⚡ LightGBM Regressor

- **المبدأ:** Gradient boosting محسن للسرعة
- نفس الدقة تقريباً، XGBoost **القوة:** أسرع من
- **مناسب لـ:** البيانات الضخمة والإنتاج
- **المعاملات المهمة:**
 - `num_leaves`: عدد الأوراق (300-31)
 - `learning_rate`: معدل التعلم (0.3-0.01)

8. 🎯 CatBoost Regressor

- **المبدأ:** Gradient boosting مع معالجة متقدمة للـ categorical features
- **القوة:** hyperparameter tuning أقل حاجة لـ
- **المعاملات المهمة:**
 - `iterations`: عدد الـ rounds (100-1000)
 - `depth`: عمق الأشجار (10-4)

9. ✂ Support Vector Regression (SVR)

- **المبدأ:** margin يحتوي أكبر عدد من النقاط ضمن hyperplane
- **القوة:** فعال مع البيانات عالية الأبعاد
- **المعاملات المهمة:**
 - `C`: قوة التنظيم
 - `kernel`: نوع الـ kernel ('linear', 'rbf')
 - `epsilon`: margin عرض الـ

10. 🌲 Decision Tree Regressor

- **المبدأ:** شجرة من القواعد البسيطة للتنبؤ بالقيم
- **القوة:** سهل الفهم والتصور
- **نقاط الضعف:** overfitting جداً سريع

11. 🎯 K-Nearest Neighbors Regressor

- **المبدأ:** K جيران يتنبأ بناءً على متوسط أقرب
- **القوة:** بسيط، يتعامل مع الأنماط المحلية
- **نقاط الضعف:** بطيء مع البيانات الكبيرة

12. 🧠 Neural Networks (MLPRegressor)

- المبدأ: شبكة عصبية متعددة الطبقات
- القوة: يتعلم أي علاقة معقدة
- يحتاج: بيانات كثيرة ووقت تدريب طويل

متى نستخدم كل نموذج؟

🎯 حسب نوع العلاقة:

علاقة خطية بسيطة:

- Linear Regression (baseline)
- Ridge (مع multicollinearity)
- Lasso (مع متغيرات كثيرة)

علاقة غير خطية:

- XGBoost/LightGBM (الأفضل)
- Random Forest
- Neural Networks

بيانات فئوية كثيرة:

- CatBoost (الأمثل)
- XGBoost/LightGBM

📊 حسب حجم البيانات:

حجم البيانات	الأفضل	البديل
< 1K	Linear/Ridge/Lasso	Decision Tree
1K-10K	Random Forest	XGBoost
10K-100K	XGBoost	LightGBM

حجم البيانات	الأفضل	البديل
100K-1M	LightGBM	XGBoost
> 1M	LightGBM	Linear Regression

🏠 حسب الهدف:

فهم العلاقات والتأثيرات:

1. Linear Regression
2. Ridge/Lasso
3. Decision Tree

أقصى دقة ممكنة:

1. **XGBoost**
2. **LightGBM**
3. **CatBoost**

سرعة في الإنتاج:

1. **LightGBM**
2. Linear Regression
3. **XGBoost**

مع بيانات معقدة:

1. **Gradient Boosting Family**
2. Neural Networks
3. Random Forest

نصائح للاختيار العملي

🚀 استراتيجية البداية السريعة:

1. **Linear Regression** (baseline سريع)
2. **XGBoost** أو **LightGBM** (أداء قوي)
3. **Neural Networks** → إذا النتائج مش كافية

💡 للمشاريع الحقيقية:

- **LightGBM**: تطوير سريع
- **XGBoost**: إنتاج مستقر
- **Ridge/Lasso**: تفسير مطلوب
- من عدة نماذج Ensemble دقة قصوى

⚠ تحذيرات مهمة:

- **Linear models**: تفترض علاقة خطية
- **Tree models**: outliers حساسة للـ
- **KNN**: curse of dimensionality
- **Neural Networks**: يحتاج بيانات كثيرة جداً

🏆 الاختيار الذهبي لمعظم المشاكل:

1. **Ridge Regression** (فهم البيانات) ابدأ بـ
2. **LightGBM** (أداء قوي) جرب
3. **hyperparameter tuning** مع **XGBoost** → إذا عايز دقة أكثر

مقاييس التقييم المناسبة

النموذج	المقياس الأفضل	السبب
Linear Models	R^2 + RMSE	سهل التفسير

النموذج	المقياس الأفضل	السبب
Tree Models	MAE + RMSE	outliers مقاوم للـ
Boosting Models	Custom metrics	مرونة في التحسين
Neural Networks	MSE + validation curves	overfitting مراقبة

M Records تطبيق عملي لـ 2

للبينات بحجم 2 مليون:

- 1. **LightGBM**: (سرعة + دقة)
- 2. **Linear Models**: baseline للـ السريع
- 3. **XGBoost**: إذا الوقت مش مشكلة
- 4. **KNN/SVR**: مش عملي خالص ❌

مقترح Pipeline:

تقييم النتائج → LightGBM → StandardScaler → EDA → البيانات